Rapport de recherche : Bibliothèque ByzFL

Étude de la robustesse dans l'apprentissage fédéré

ABBES Samy & AREZKI Célia

Semaine de 04 Mai 2026

1 Introduction

Ce rapport présente le travail effectué lors de notre première phase de recherche sur l'apprentissage fédéré avec **ByzFL**. Nous y détaillons notre processus d'apprentissage de l'outil **ByzFL**, la conception de notre première expérience sur le jeu de données MNIST, ainsi que l'évolution de nos résultats suite aux corrections techniques apportées.

2 Prise en main de la bibliothèque

La première semaine de notre TER a été consacrée à l'exploration et à la prise en main de la bibliothèque **ByzFL**. Cette phase nous a permis de comprendre l'implémentation modulaire de l'outil à travers ses quatre composantes fondamentales :

- **DataDistributor** : Responsable de la partition des données entre les clients (distributions IID ou non-IID).
- **Client** : Simule les entités honnêtes réalisant l'entraînement local et le calcul des gradients.
- **ByzantineClient** : Simule les attaquants capables de corrompre les gradients avant leur envoi.
- **Server** : Point central qui orchestre l'agrégation des gradients reçus et met à jour le modèle global.

Nous avons également étudié les différentes méthodes d'agrégation robuste (*TrMean, Krum, Median...etc*) et les types d'attaques (*SignFlipping, IPM, ALIE...etc*) proposés par la bibliothèque pour comprendre leurs fondements mathématiques.

3 Contenu de l'expérience MNIST

Notre première expérience pratique vise à évaluer la résistance d'un modèle de réseau de neurones (*cnn_ mnist*) face à diverses perturbations. Le but est de confronter des mécanismes de défense à des stratégies d'attaque spécifiques.

L'expérience consiste à comparer plusieurs combinaisons :

- **Baseline** : Une agrégation simple (*Average*) sans aucune attaque pour établir le score de référence.
- **Attaque brute vs Défense simple** : *SignFlipping* contre une moyenne (*Average*) et contre une médiane (*Median*).
- **Attaque optimisée vs Défense statistique** : *Inner Product Manipulation (IPM)* contre la moyenne tronquée (*TrMean*).
- **Attaque furtive vs Défense géométrique** : *A Little Is Enough (ALIE)* contre l'algorithme *Krum*.

L'objectif global est d'observer si les agrégateurs robustes parviennent à maintenir une précision élevée là où une moyenne classique échouerait.

4 Historique et Évolution de l'expérience

4.1 Phase 1 : Résultats initiaux et difficultés

Lors de nos premiers tests, nous avons obtenu des résultats très médiocres. Le modèle ne parvenait pas à apprendre, avec une précision finale stagnante aux alentours de 10-13%, ce qui correspondait quasiment à un choix aléatoire sur les 10 classes de MNIST.

Paramétrages de l'époque :

— **Nombre de rounds** : 3 (trop faible pour une convergence).

— **Momentum** : 0.9 (potentiellement trop instable pour ce début d'entraînement).

4.2 Phase 2 : Correction et succès

Après une vérification rigoureuse du code avec notre professeur, nous avons identifié que le nombre de cycles d'apprentissage était insuffisant et que certains hyperparamètres nuisaient à la stabilité. En corrigeant ces éléments, nous avons obtenu des résultats conformes aux attentes.

Nouveaux paramétrages :

— **Nombre de rounds** : 1000 (permettant une convergence complète).

— **Momentum** : 0.1 (pour une mise à jour plus stable des gradients).

5 Résultats finaux (Distribution IID)

Voici les performances obtenues après correction du protocole :

6 Résultats finaux et Comparaison

Le tableau ci-dessous présente la comparaison entre notre première tentative (infructueuse) et l'expérience corrigée. On observe que l'ajustement du nombre de rounds et du momentum a permis au modèle de passer d'un état de non-apprentissage à une convergence quasi-parfaite.

Scénario	**Agrégateur**	**Attaque**	**Acc. (3 rounds)**	**Acc. (1000 rounds)**
clean_average	Average	None	0.1217	**0.9876**
signflip_average	Average	SignFlipping	0.1202	0.9849
signflip_median	Median	SignFlipping	0.1161	0.9832
ipm_trmean	TrMean	IPM	0.1305	0.9777
alie_krum	Krum	ALIE	0.1041	0.9831

TABLE 1 – Comparaison des performances : Expérience initiale vs Expérience corrigée

7 Analyse et Conclusion

Le passage de 3 à 1000 rounds a transformé une expérience médiocre en un succès technique. Nous avons validé que dans une distribution IID avec un seul attaquant, les défenses proposées par **ByzFL** sont extrêmement efficaces, limitant la perte de précision à moins de 1% par rapport au cas sain. La prochaine étape consistera à complexifier la distribution des données (Non-IID) pour tester les limites de ces agrégateurs.